BÁO CÁO TỔNG KẾT ĐỒ ÁN MÔN HỌC

Tên đề tài: Xây dựng hệ thống phân loại giấy tờ tùy thân (eKYC) ứng dụng MLOps trên nền tảng Azure (Đề tài 13) **Nhóm thực hiện:** Phúc, Tân, Phước

I. MỤC TIÊU VÀ YÊU CẦU ĐỀ TÀI (ĐỀ TÀI 13)

Dự án được thực hiện nhằm đáp ứng đầy đủ các yêu cầu của Đề tài 13, tập trung vào việc xây dựng luồng quy trình học máy (Machine Learning Pipeline) hoàn chỉnh trên nền tảng điện toán đám mây. Cụ thể:

1. **Bài toán AI Cốt lõi:** Xây dựng mô hình Computer Vision có khả năng tự động nhận diện và phân loại 3 nhóm hình ảnh:
   - **ID_Card:** Chứng minh nhân dân / Căn cước công dân.
   - **Passport:** Hộ chiếu.
   - **Invalid:** Ảnh không hợp lệ (Phong cảnh, rác, mờ nhòe...).
2. **Yêu cầu về MLOps:** Không chỉ dừng lại ở việc huấn luyện mô hình cục bộ, đề tài yêu cầu áp dụng quy trình MLOps để:
   - Quản lý phiên bản dữ liệu (Data Versioning).
   - Theo dõi thực nghiệm huấn luyện (Experiment Tracking).
   - Đóng gói và lưu trữ mô hình trung tâm (Model Registry).
3. **Môi trường Triển khai:** Toàn bộ hệ thống từ dữ liệu, máy ảo tính toán đến theo dõi mô hình phải được khởi tạo và cấu hình hoàn toàn trên nền tảng đám mây **Microsoft Azure**.

II. CÔNG CỤ VÀ MÔI TRƯỜNG PHÁT TRIỂN

- **Nền tảng Cloud:** Azure Portal, Azure Machine Learning Studio, Azure Blob Storage.
- **Môi trường tính toán:** Máy ảo Azure Compute Instance (JupyterLab).
- **Framework AI:** PyTorch, Torchvision (Python).
- **Thư viện xử lý dữ liệu:** Pandas, Pillow (PIL), `mltable`, `fsspec`, `requests`.
- **Công cụ MLOps:** MLflow, Azure MLClient.

III. KIẾN TRÚC MÔ HÌNH VÀ THUẬT TOÁN (Model Architecture)

Nhóm không tự xây dựng mạng Neural từ đầu mà sử dụng kỹ thuật **Transfer Learning (Học chuyển giao)** kết hợp **Fine-Tuning (Tinh chỉnh)** để đạt hiệu quả cao nhất với lượng dữ liệu nhỏ (~501 ảnh).

- **Mô hình cơ sở (Base Model):** `MobileNetV2` (Đã được huấn luyện trước trên tập dữ liệu khổng lồ ImageNet). Lý do chọn: Gọn nhẹ, tốc độ suy luận nhanh, phù hợp triển khai lên thiết bị di động.
- **Chiến lược Fine-Tuning:**

  - **Đóng băng (Freeze):** Giữ nguyên trọng số của các lớp trích xuất đặc trưng cơ bản ở phần đầu mô hình.
  - **Mở khóa (Unfreeze):** Mở khóa 5 block cuối cùng của kiến trúc MobileNetV2 để ép mô hình học các đặc trưng chi tiết chuyên biệt của thẻ Căn cước và Hộ chiếu (như quốc huy, màu xanh hộ chiếu, mã vạch).
  - **Lớp phân loại (Classifier):** Thay đổi lớp Fully Connected cuối cùng từ 1000 nhãn (mặc định) xuống còn **3 nhãn** đầu ra.
- **Hàm mất mát (Loss Function):** Sử dụng `CrossEntropyLoss` kết hợp **Class Weights (Trọng số lớp)** `[3.0, 3.0, 1.0]`. Trọng số này ép mô hình phải tập trung gấp 3 lần vào việc nhận diện ID và Passport, phạt nặng nếu đoán sai.
- **Tối ưu hóa (Optimizer):** Thuật toán `Adam` với Learning Rate khởi tạo là `0.0003`.
- **Điều phối tốc độ học (Scheduler):** Dùng `StepLR` để tự động giảm tốc độ học (gamma=0.5) sau mỗi 5 Epochs.

IV. CÁC BƯỚC KHỞI TẠO VÀ TRIỂN KHAI TRÊN AZURE

Để hoàn thành dự án theo đúng chuẩn MLOps, nhóm đã thực hiện thao tác thiết lập toàn bộ hạ tầng từ con số 0 trên nền tảng Azure với các bước chi tiết sau:

Bước 1: Khởi tạo Hạ tầng cơ sở (Azure Portal)

- Truy cập trang chủ Azure Portal.
- Khởi tạo **Resource Group** mới để nhóm toàn bộ tài nguyên của dự án eKYC vào một khu vực quản lý chung (Ví dụ: `eKYC_Project_RG`).
- Tìm kiếm dịch vụ **Azure Machine Learning**, tiến hành tạo một **Workspace** mới nằm trong Resource Group vừa tạo. Hệ thống sẽ tự động khởi tạo kèm theo Storage Account, Key Vault, Application Insights và Container Registry phục vụ cho dự án.

Bước 2: Thiết lập Máy ảo tính toán (Compute Instance)

- Mở **Azure Machine Learning Studio** từ Workspace vừa tạo.
- Chuyển đến mục **Compute** -> **Compute instances** và tạo một máy ảo tính toán (Ví dụ loại `Standard_DS11_v2` hoặc có hỗ trợ GPU nếu cần).
- Sau khi máy ảo chuyển trạng thái *Running*, mở môi trường **JupyterLab** để chuẩn bị cho việc lập trình.

Bước 3: Đưa dữ liệu lên Container và Gán nhãn (Data Storage & Labeling)

Đây là quy trình chuẩn trong việc quản lý Data Lake trên Cloud:

- **Lưu trữ trên Blob Storage:** Truy cập vào Storage Account của dự án trên Azure Portal. Tại mục Containers, tạo một **Container** mới (ví dụ: `ekyc-raw-images`). Nhóm tiến hành tải toàn bộ ~501 hình ảnh thô (gồm CMND, Hộ chiếu, ảnh rác) vào Container này.

- **Kết nối Datastore:** Trở lại Azure ML Studio, tạo một **Datastore** mới và móc nối (mount) nó với Container vừa tạo ở trên để cấp quyền cho Azure ML truy cập kho ảnh.
- **Gán nhãn (Data Labeling):** Chuyển sang mục **Data Labeling**, tạo một Project gán nhãn mới và chọn nguồn dữ liệu từ Datastore chứa kho ảnh. Nhóm tiến hành thao tác gán nhãn thủ công (Human-in-the-loop) với 3 class: `ID_Card`, `Passport`, `Invalid`.
- **Xuất dữ liệu (Data Versioning):** Xuất dữ liệu đã hoàn thiện thành Data Asset định dạng **Azure MLTable** (với tên `eKYC_Labeling_Team_20260502_`) để tích hợp vào Pipeline huấn luyện.

Bước 4: Xử lý dữ liệu và Huấn luyện (Data Preprocessing & Training Loop)

Đây là bước đột phá kỹ thuật lớn nhất của nhóm khi xử lý thành công các dị thường của cấu trúc dữ liệu trên Cloud:

- **Bộ nạp ảnh bất tử (Universal Image Loader):** Viết lại module đọc ảnh tích hợp `fsspec` và `requests` để trực tiếp giải mã các luồng dữ liệu (StreamInfo), liên kết nội bộ (`azureml://`) và HTTP URL, khắc phục triệt để sự cố thư viện tiêu chuẩn không đọc được file Cloud.
- **Xử lý nhãn thông minh (String Matching):** Xử lý sự cố Azure trả về nhãn dưới dạng chuỗi JSON chứa tọa độ (Bounding Box) bằng thuật toán khớp chuỗi tự động trích xuất đúng tên class.
- **Huấn luyện:** Chia dữ liệu theo tỷ lệ 80/20, áp dụng Data Augmentation và huấn luyện qua 15 Epochs với DataLoader (có cấu hình `drop_last=True`).

Bước 5: Giám sát MLflow và Lưu trữ Mô hình (MLOps Tracking & Registry)

- Tích hợp cấu hình `mlflow.set_experiment()` để khởi tạo phiên theo dõi.
- Tại mỗi Epoch, các số đo (Metric) như Train/Val Accuracy, Loss đều được hàm `mlflow.log_metric()` bắt lại và gửi lên đám mây.
- Nhóm truy cập mục **Jobs** trên Azure ML Studio để quan sát biểu đồ hiệu suất mô hình thời gian thực.
- Mô hình tốt nhất đạt Val Acc ~84.16% được tự động đóng gói bằng `mlflow.log_artifact()` và lưu thành file `ekyc_mobilenet_v2_ultimate.pth` trong thư mục Artifacts của Azure, hoàn thành vòng đời huấn luyện (Training Lifecycle).
- Thực hiện **Stop** máy ảo Compute Instance để tiết kiệm chi phí.

V. KẾT QUẢ VÀ ĐÁNH GIÁ

- **Kết quả đo lường:** Quá trình huấn luyện hội tụ rất mượt, độ chính xác trên tập Train đạt **~94%** và trên tập thi thử (Validation) đạt **~84.16%**.
- **Đánh giá:** Với giới hạn tập dữ liệu tương đối nhỏ (~500 ảnh), con số 84% phản ánh sự học tập chân thực của mô hình và không mắc lỗi học vẹt (Overfitting). Mô hình phân biệt rõ ràng các đặc điểm cốt lõi của giấy tờ tùy thân nhờ kỹ thuật Fine-Tuning và Class Weights.

- **Mức độ hoàn thành Đề tài:** Đã đáp ứng xuất sắc yêu cầu của Đề tài 13. Toàn bộ Pipeline đã được triển khai khép kín trên Azure (từ dữ liệu, huấn luyện đến MLOps log). Chỉ cần bổ sung thêm lượng ảnh gán nhãn, độ chính xác sẽ dễ dàng tiệm cận 99%, sẵn sàng Deploy.